

Regularni izrazi za HTML – Povzetek za Prog 2

Osnove regularnih izrazov

. = poljuben znak
* = 0 ali več ponovitev
+ = 1 ali več ponovitev
? = 0 ali 1 pojavitev oziroma negreedy modifikator
\d = cifra
\w = črka, cifra ali _
\s = presledek/tab/nova vrstica
[abc] = eden od znakov
[^abc] = karkoli razen a,b,c
() = zajemna skupina
| = ali

Izluščitev URL-ja

Regex: href="([^\"]+)"

Izluščitev besedila povezave

Regex: >([^\<]+)<

Naslovi linkov

Regex: <h2>(.*)</h2>

Greedy vs Non-greedy

Praviloma pri HTML uporabljaj (.*?) namesto (.*)

Atributi

```
src="([^\"]+)"
alt="([^\"]+)"
```

Tabele

```
<td>(.*)</td>
```

Python primer

```
import re
naslovi = re.findall(r'<h2>(.*)</h2>', html)
```

Java primer

```
Pattern p = Pattern.compile("<h2>(.*)</h2>");
```

Tipične izpitne naloge

Najdi vse povezave: <a[^>]*href="([^\"]+)"

Email: [w.-]+@[w.-]+\lw+

Števila: \d+

Vrstice tabele: <tr>(.*)</tr>

Celice tabele: <td>(.*)</td>

Goljufijski list

\d+ = števila

\w+ = besede

\s+ = presledki

[^"]+ = vse do narekovaja

[^<]+ = vse do HTML taga

<tag>(.*?)</tag>

href="([^\"]+)"

src="([^\"]+)"

alt="([^\"]+)"

<a.*?href="(.*?)".*?>(.*?)